

# Informe Taller 1

## Modelado y Análisis de una Red de Artículos de Wikipedia

Carlos Bugueño, Constantino Bekios y Vicente Moyano

15 de mayo de 2026

### 1. Introducción

Wikipedia corresponde a una de las redes de información más grandes existentes en internet. Cada artículo posee enlaces hacia otros artículos, generando una estructura compleja de relaciones que puede representarse matemáticamente mediante grafos dirigidos.

En este proyecto se desarrolló un sistema en Python orientado a objetos capaz de modelar y analizar una red de artículos de Wikipedia utilizando un subconjunto del dataset entregado. El sistema implementa estructuras de grafos, recorridos BFS y DFS, métricas estructurales y una versión simplificada del algoritmo PageRank.

El objetivo principal fue analizar cómo se relacionan los artículos dentro de la red e identificar cuáles poseen mayor relevancia estructural.

### 2. Objetivos

#### 2.1. Objetivo General

Desarrollar un sistema orientado a objetos para modelar y analizar una red de artículos de Wikipedia utilizando grafos dirigidos.

#### 2.2. Objetivos Específicos

- Representar artículos y enlaces mediante clases.
- Construir un grafo dirigido a partir de datos reales.
- Implementar recorridos BFS y DFS.
- Calcular métricas estructurales.
- Implementar una versión simplificada de PageRank.
- Analizar artículos relevantes dentro de la red.

### 3. Herramientas y Tecnologías Utilizadas

#### 3.1. Python

Python fue utilizado debido a su facilidad para trabajar con estructuras de datos y programación orientada a objetos. Además, permitió implementar algoritmos de grafos de forma clara y modular.

### **3.2. Programación Orientada a Objetos**

La programación orientada a objetos permitió dividir el sistema en responsabilidades específicas mediante distintas clases.

Esto facilitó:

- La organización del proyecto.
- La reutilización de código.
- La mantención del sistema.
- La representación natural de nodos y conexiones.

### **3.3. Visual Studio Code**

Visual Studio Code fue utilizado como entorno de desarrollo debido a sus herramientas de depuración, organización de archivos y compatibilidad con Python.

### **3.4. Google Colab**

Google Colab fue utilizado inicialmente para ejecutar pruebas rápidas y trabajar con el dataset sin depender completamente del entorno local.

### **3.5. GitHub**

GitHub permitió respaldar el proyecto y mantener control de versiones del código desarrollado.

## **4. Desarrollo del Sistema**

### **4.1. Modelado del Grafo**

La red de Wikipedia fue modelada como un grafo dirigido donde:

- Cada nodo representa un artículo.
- Cada arista representa un enlace desde un artículo hacia otro.

Para representar esta estructura se implementaron las siguientes clases:

- `ArticuloWikipedia`
- `GrafoWikipedia`
- `CargadorWikipedia`
- `ReporteBasicoWikipedia`

## 4.2. Clase `ArticuloWikipedia`

Representa un artículo individual y almacena:

- ID del artículo.
- Nombre.
- Enlaces de entrada.
- Enlaces de salida.
- Categorías.

También incluye métodos para agregar enlaces y calcular grados.

## 4.3. Clase `GrafoWikipedia`

Representa el grafo completo y contiene la lógica principal del sistema.  
Fue utilizada para:

- Agregar artículos.
- Conectar nodos.
- Ejecutar BFS y DFS.
- Buscar caminos entre nodos.
- Calcular PageRank.

## 4.4. Uso de `yield`

Durante la carga de enlaces se utilizó `yield` para leer progresivamente el archivo del dataset.  
Esto fue importante debido al gran tamaño de los datos, permitiendo optimizar el uso de memoria y evitando cargar todo el archivo simultáneamente.

# 5. Implementación de Algoritmos

## 5.1. BFS

El recorrido BFS fue implementado utilizando una cola.  
Este algoritmo permitió:

- Explorar nodos por niveles.
- Encontrar caminos mínimos entre artículos.
- Analizar conectividad.

## 5.2. DFS

DFS fue implementado utilizando una pila.  
Este algoritmo permitió explorar caminos profundos dentro de la red antes de retroceder.

### 5.3. PageRank

Se implementó una versión simplificada de PageRank utilizando:

- Factor de amortiguación de 0.85.
- 10 iteraciones.

PageRank fue utilizado para identificar artículos importantes dentro de la red considerando no solamente la cantidad de enlaces recibidos, sino también la relevancia de los artículos que los enlazan.

## 6. Resultados Obtenidos

### 6.1. Resumen del Grafo

- Cantidad de artículos: 5000
- Cantidad de enlaces: 2419

A pesar de trabajar únicamente con un subconjunto del dataset original, el grafo generado logró mantener una estructura suficientemente compleja para realizar análisis relevantes.

### 6.2. Nodos con Mayor Grado de Entrada

Los artículos con mayor cantidad de enlaces entrantes fueron:

1. Buprestidae
2. Buprestoidea
3. Adrian Monk
4. Natalie Teeger
5. Randy Disher

Estos resultados indican que ciertos artículos funcionan como puntos centrales dentro de la red, recibiendo referencias desde múltiples nodos.

Se observó un patrón importante: muchos de los artículos con mayor grado pertenecen a categorías altamente relacionadas entre sí, especialmente artículos asociados a taxonomía de insectos y series de televisión.

Esto demuestra que Wikipedia tiende a formar comunidades temáticas altamente conectadas.

### 6.3. Nodos con Mayor Grado de Salida

Los artículos con más enlaces salientes fueron:

1. Agrilinae
2. Buprestinae
3. Chrysobothridae
4. Polycestinae
5. Buprestidae

Estos artículos poseen gran cantidad de conexiones hacia otros nodos, funcionando como distribuidores de información dentro de la red.

Se identificó que muchos artículos taxonómicos contienen referencias hacia numerosas especies o subcategorías, generando nodos altamente conectados.

## 6.4. Resultados de BFS y DFS

Los recorridos BFS y DFS permitieron comprobar conectividad entre nodos específicos del grafo.

El BFS permitió recorrer nodos cercanos rápidamente y encontrar caminos mínimos entre artículos relacionados.

DFS permitió explorar rutas más profundas dentro del grafo, verificando la existencia de conexiones indirectas.

Ambos algoritmos demostraron que incluso un subconjunto reducido de Wikipedia mantiene una estructura conectada y navegable.

## 6.5. Resultados de PageRank

Los artículos con mayor PageRank fueron:

1. Buprestidae
2. Buprestoidea
3. Schizopodidae
4. American Beetles
5. Michael C. Thomas

Los resultados obtenidos muestran una fuerte relación entre PageRank y la estructura de enlaces del grafo.

Se observó que los artículos más importantes corresponden principalmente a nodos altamente referenciados dentro de comunidades temáticas específicas.

Sin embargo, también se identificó un patrón interesante: algunos artículos no poseían necesariamente el mayor grado de entrada, pero aun así obtenían un PageRank elevado debido a que eran enlazados por nodos importantes.

Esto demuestra que PageRank no mide únicamente cantidad de enlaces, sino también calidad estructural de las conexiones.

## 7. Análisis General

El análisis realizado permitió identificar que Wikipedia presenta características similares a otras redes complejas reales.

Uno de los principales patrones encontrados fue la existencia de nodos centrales o hubs, los cuales concentran gran parte de las conexiones de la red.

También se observaron comunidades temáticas claramente definidas. Los artículos relacionados con taxonomía de insectos tendían a conectarse principalmente entre sí, formando grupos densamente enlazados.

Otro aspecto importante fue comprobar que la red no distribuye conexiones de manera uniforme. La mayoría de los nodos poseen pocos enlaces, mientras que unos pocos concentran gran parte de la conectividad total.

Este comportamiento corresponde a una distribución típica de redes reales complejas.

Además, los resultados de PageRank evidenciaron que la relevancia de un artículo depende no solamente de la cantidad de enlaces recibidos, sino también de la importancia de quienes lo enlazan.

## 8. Conclusiones

El proyecto permitió modelar exitosamente una red de artículos de Wikipedia utilizando grafos dirigidos y programación orientada a objetos.

La implementación de BFS, DFS y PageRank permitió analizar conectividad, relevancia y estructura interna de la red.

El uso de clases permitió organizar adecuadamente el sistema y separar responsabilidades, facilitando la mantención y expansión futura del proyecto.

Los resultados obtenidos permitieron identificar patrones estructurales importantes, como la presencia de hubs y comunidades temáticas altamente conectadas.

Finalmente, el proyecto permitió aplicar conocimientos relacionados con:

- Programación orientada a objetos.
- Estructuras de datos.
- Teoría de grafos.
- Algoritmos de búsqueda.
- Análisis de redes complejas.